RNA-MLP | Demonstração

Dados sintéticos · Projeto para portfólio

Este projeto demonstra um fluxo de dados tabulares: limpeza, separação por grupos, treinamento de uma rede MLP e avaliação. Todos os registros foram gerados por código. Nenhum município, estabelecimento, equipe ou volume de produção corresponde a uma observação real.

MSE de teste = 0.030188 | Acurácia após arredondamento = 99.87%

1. Dados e protocolo

A base tem 7,979 registros. As categorias de região usam nomes conhecidos apenas como rótulos; as UFs XA-XJ são fictícias. Os identificadores IBGE, CNES e INE são marcadores sintéticos, sem vínculo com cadastros oficiais. A semente do gerador e do treinamento é 101.

O gerador inclui classes desbalanceadas, valores ausentes e uma distribuição de Total com cauda à direita. Os números de identificação são aleatórios e independentes da região. Cada UF fictícia pertence a uma região por construção, tornando a relação aprendível e deliberadamente simples.

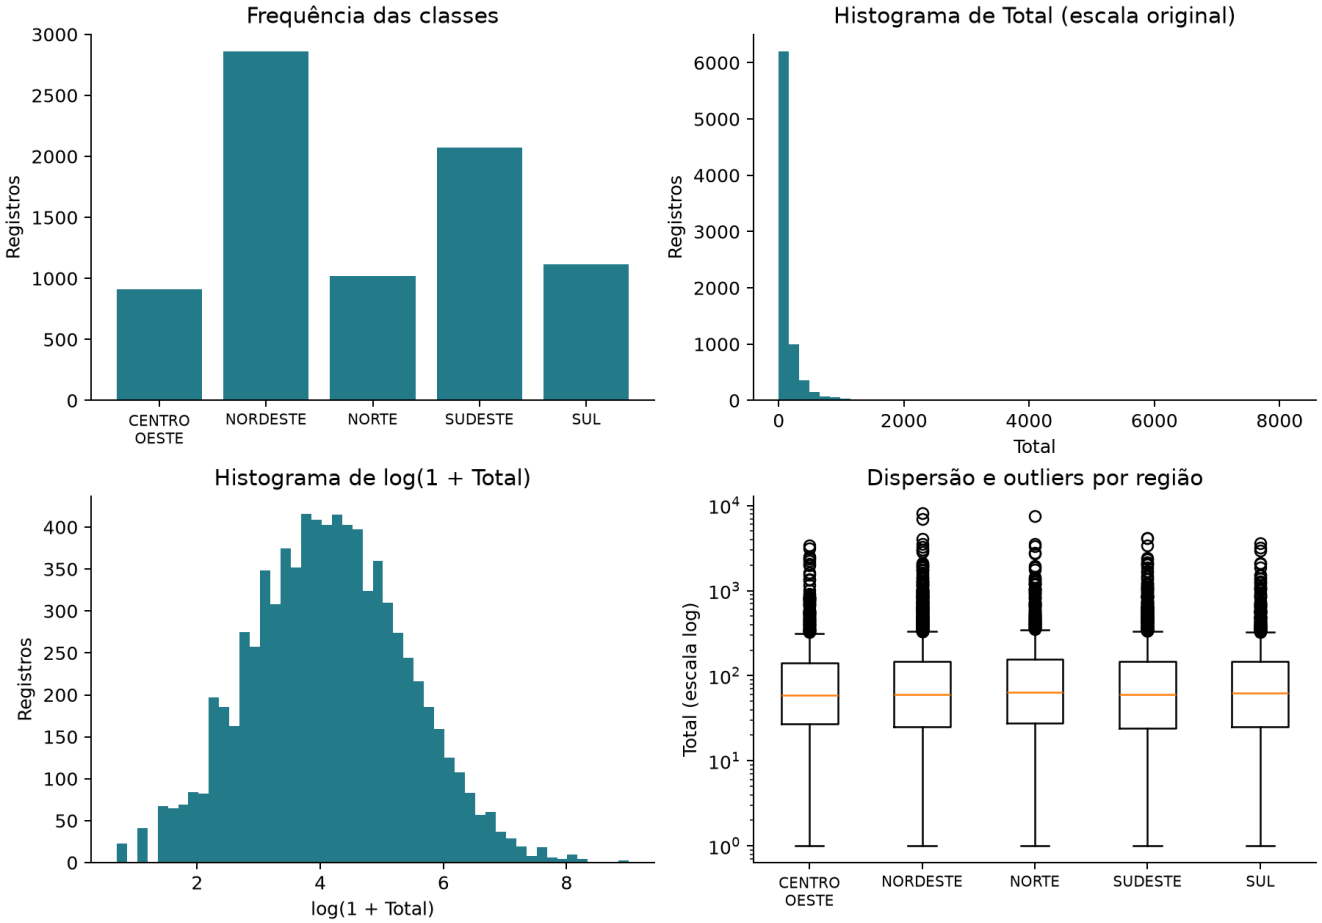
Ausência original	Tratamento
Tipo Unidade: 2,816	Categoria AUSENTE
INE: 789	Sentinela -1
Tipo Equipe: 3,216	Categoria AUSENTE

Textos são padronizados sem acentos, espaços viram sublinhados e Total é lido como contagem inteira: 2.016 significa 2016. A codificação ordinal e a normalização MinMax são ajustadas apenas no treino. Categorias inéditas recebem -1. Regiao é excluída das nove entradas explicitamente.

Partição	Registros	Municípios fictícios
treino	4803	300
validacao	1577	100
teste	1599	100

A separação é feita por município, com 60% dos grupos para treino, 20% para validação e 20% para teste, estratificada por região. Todas as linhas de um município ficam juntas. A proporção de linhas varia com o tamanho de cada grupo.

2. Distribuição dos dados



Região / código	Registros	Proporção
NORDESTE / 1	2859	35.83%
SUDESTE / 3	2075	26.01%
SUL / 4	1114	13.96%
NORTE / 2	1021	12.80%
CENTRO_OESTE / 0	910	11.40%

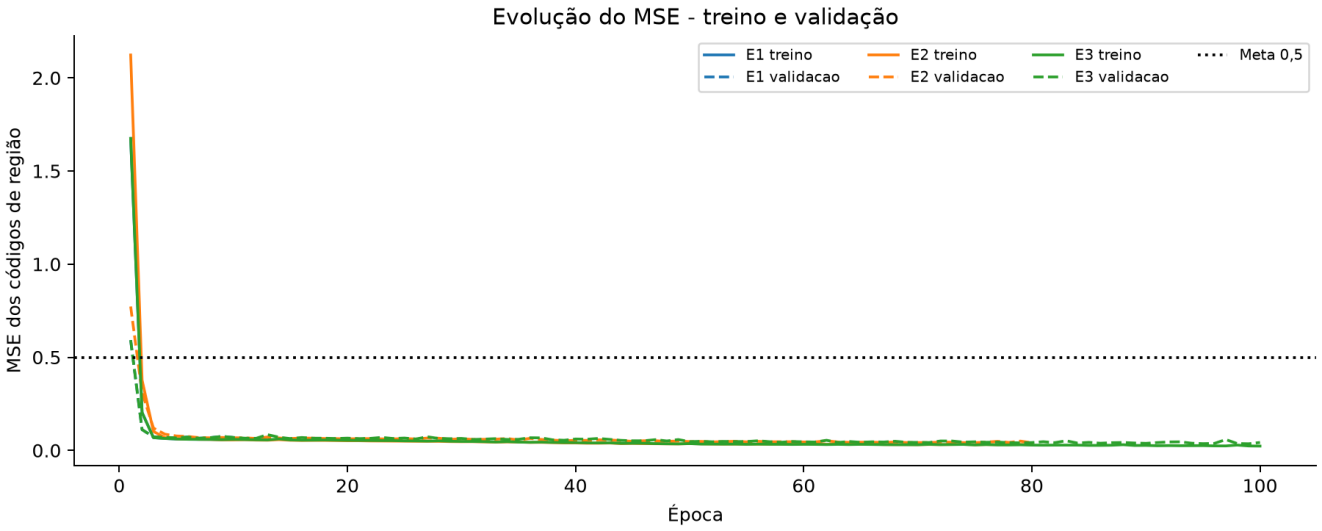
A classe dominante é NORDESTE. Total tem mediana 61.0, média 143.57 e máximo 8,180. A regra Q3 + 1,5 IQR identifica 770 valores acima de 330.0. Os outliers são preservados: fazem parte da distribuição simulada. O logaritmo é usado apenas na visualização.

3. Treinamento

A rede recebe nove entradas: Uf, IBGE, Municipio, CNES, Tipounidade, INE, Tipoequipe, Validacao e Total. Uma Dense linear de nove unidades precede as camadas ocultas ReLU e a saída linear. O otimizador é Adam e a perda é MSE. A execução usa CPU e operações determinísticas.

Teste	Ocultas	Épocas máx./rodadas	Melhor época	MSE validação
E1	[100, 100]	10/10	7	0.065439
E2	[64, 32]	80/80	80	0.040858
E3	[100, 100]	100/100	99	0.035537

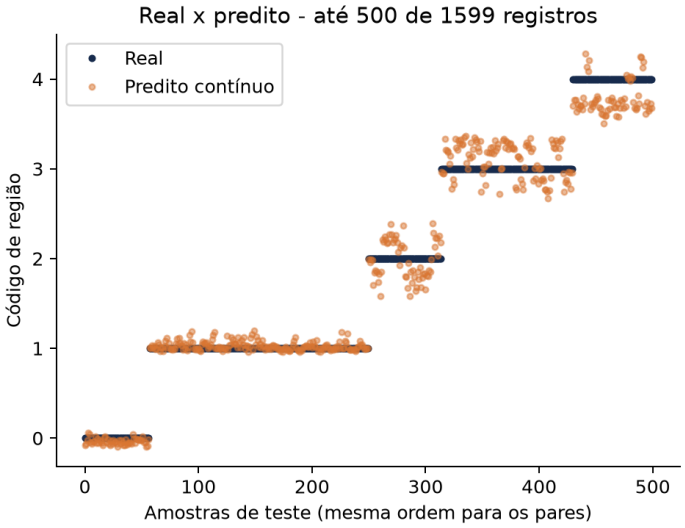
E3 foi selecionado pelo menor MSE de validação. Batch = 64; learning rate = 0.001. Early stopping tem paciência de 15 épocas e restaura os melhores pesos. O teste não participa da seleção de hiperparâmetros.

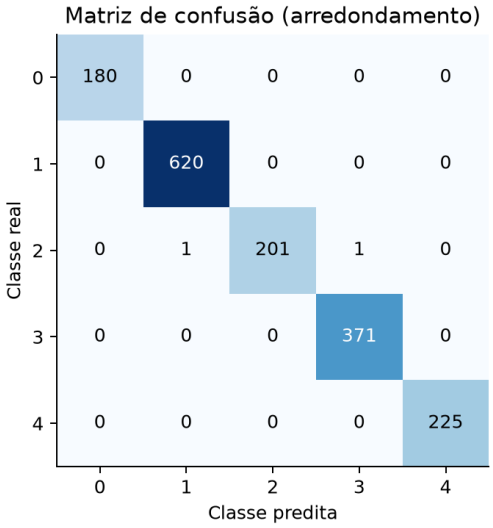


São comparadas duas larguras de rede e diferentes limites de épocas. Os gráficos e as tabelas vêm dos históricos efetivamente produzidos nesta execução; resultados anteriores não são reaproveitados.

Regiao é nominal. A saída linear e as métricas de regressão foram preservadas da versão didática que originou o projeto. O MSE depende da ordem arbitrária dos códigos e não mede distância geográfica. Para um problema real de classificação, uma saída softmax e avaliação por classe seriam escolhas mais adequadas.

4. Avaliação e limites





Métrica	Estimativa	IC95% inferior	IC95% superior
MSE	0.030188	0.023737	0.037241
MAE	0.127541	0.107298	0.148928
R2	0.981400	0.975536	0.985481
EVS	0.981402	0.975755	0.985728

Referência constante, média do alvo no treino: MSE = 1.626421. A acurácia complementar é 99.87%, calculada após arredondar e limitar as previsões a 0-4. As demais métricas usam previsões contínuas. O gráfico mantém os pares real/predito da mesma linha.

Codificação do alvo: CENTRO_OESTE = 0; NORDESTE = 1; NORTE = 2; SUDESTE = 3; SUL = 4.

Os intervalos usam 1,000 reamostragens dos municípios de teste com reposição, mantendo todas as linhas e seus pares em cada grupo. São os percentis 2,5% e 97,5%, condicionados ao modelo treinado e à divisão atual. Não medem a variação entre novos treinamentos.

Categorias inéditas no teste: Uf: 0; Municipio: 1599; Tipounidade: 0; Tipoequipe: 0; Validacao: 0.

Resultados sintéticos demonstram o funcionamento do pipeline. Não validam desempenho em dados reais, representatividade regional ou aplicação em saúde. A relação UF-região foi inserida pelo próprio gerador; um mapeamento direto poderia resolver essa tarefa sem rede neural.

Reprodução

Execute python executar.py na raiz do projeto. O gerador recria data/dados_sinteticos.csv; o pipeline grava o modelo, os dados tratados, as partições, as métricas, os gráficos e este relatório em output/. O notebook Projeto_RNA_MLP.ipynb apresenta o mesmo fluxo. O README documenta o ambiente e os resultados medidos.